

گزارش سری زمانی

AUTHOR

امیرمحمد عبدالله پور

خلاصه ای از مسیر

کارهایی که با داده انجام شد

- ساختن یک ستون جدید به عنوان قیمت کل، با ضرب کردن مقدار کمیت با قیمت واحد
- داده ها از روزانه به جمع درآمد در روز، هفته و ماه تبدیل شد
- حذف کشورهای به غیر از انگلیس به دلیل اینکه تقریباً ۹۰ درصد داده ها از انگلیس آمده اند و استفاده از بقیه کشورها منطقی نیست، چون اطلاعات کافی راجع به فروش در آن کشور ها نداریم.
- حذف داده هایی که شماره خرید آنها با حرف انگلیسی C شروع می شود چون این فروش ها کنسل شده اند و درآمد از آنها نباید در فروش کل قرار بگیرد
- این داده ها در دو سری به وجود آمده اند که اولین سری از سال ۲۰۰۹ تا ۲۰۱۰ بود و سری دوم از سال ۲۰۱۰ تا ۲۰۱۱ بود که براساس زمان این ها را تبدیل به یک دیتاست کردم و به بررسی دو سال از فروش این فروشگاه می پردازم
- در تاریخ نوامبر ۲۰۱۰ تا مارچ ۲۰۱۱ به سمت پایین آمد به دلیل اینکه اکه به تاریخ در آن زمان در انگلستان نگاه کنیم متوجه اعتراضات دانشجویی می شویم
- در این فروشگاه، آخرهفته ها روز فروش نیست و درآمد به صفر میرسه و به این دلیل آخرهفته ها را از داده پاک میکنیم
- در داده یک سری قیمت منفی داشتیم که نشان دهنده، پس دادن کالا توسط مشتری ها بود که برای یکم ساده تر شدن مدل از داده حذف شد

تست هایی که گرفته شد

:Dicky-fuller (ADF) •

- برای نشان دادن مانا بودن، اگر کوچک بود نشان دهنده مانایی هست و اگه از ۰.۰۵ بزرگتر باشه مانا نیست

:Runs-test •

- برای سنجش پایانی باقی مانده ها استفاده میشه که تصادفی بودن باقی مانده ها را تایید یا رد میکنه

• کلموگیروف-اسمینیروف

- نرمال بودن یا نبودن باقی مانده را مورد سنجش میزاریم

چرا قیمت ها صفر هستند؟

در این تاریخها بازارهای مالی بریتانیا (UK) تعطیل بوده اند و هیچ معامله ای انجام نشده، بنابراین قیمت ها به صورت ۰.۰ ثبت شده اند.

کریسمس (تعطیلات پایان سال)

بازارهای بریتانیا در دوره کریسمس معمولاً چند روز بسته هستند:

31-12-2009 تا 2009-12-24 •

31-12-2010 تا 2010-12-24 •

روز سال نو

2010-01-01 •

(New Year's Day) 2011-01-03 •

تعطیلات عید پاک (Easter Holidays)

این تعطیلات شامل دو روز رسمی است: Easter Monday و Good Friday

(Good Friday – جمعه نیک 2010-04-02 •

(Easter Monday – دوشنبه عید پاک 2010-04-05 •

(جمعه نیک 2011-04-22 •

(دوشنبه عید پاک 2011-04-25 •

Early May Bank Holiday

یک تعطیلی رسمی که اولین دوشنبه ماه می برگزار می شود:

2010-05-03 •

2011-05-02 •

Spring Bank Holiday

یک تعطیلی رسمی که آخرین دوشنبه ماه می برگزار می شود:

2010-05-31 •

2011-05-30 •

Summer Bank Holiday

یک تعطیلی رسمی که آخرین دوشنبه ماه آگوست برگزار می شود:

2010-08-30 •

2011-08-29 •

عروضی سلطنتی

در این روز شاهزاده ولیام و کاترین میدلتون ازدواج کردند و دولت بریتانیا این روز را تعطیل رسمی ملی اعلام کرد -

29-04-2011

ساختار داده ها

- کشورهای که فروش در آنجا انجام شده به دلیل اینکه انگلیس اکثر داده ما را تشکیل می‌داد از بقیه کشورها صرف نظر شد و به تحلیل فقط میزان فروش در انگلیس پرداخته شد.
- یک کد مختص به یک مشتری : Customer ID
- قیمت هر واحد از کالا : Price
- تعداد خرید مشتری از یک نوع کالا : Quantity
- توضیح راجب کالا : Description
- کد مختص به سهام کالا : StockCode
- شماره خرید : Invoice
- زمان خرید : InvoiceDate
- نشان دادن اینکه در آن روز به خصوص آیا تعطیل هست یا خیر : Holiday

پیش‌پردازش داده ها

```
<'class 'pandas.core.frame.DataFrame>
DatetimeIndex: 1067371 entries, 2009-12-01 07:45:00 to 2011-12-09 12:50:00
               Data columns (total 7 columns)
   Column      Non-Null Count   Dtype   #
   --  --  --  --
   Invoice     1067371 non-null   object  0
   StockCode   1067371 non-null   object  1
   Description 1062989 non-null   object  2
   Quantity    1067371 non-null   int64   3
   Price       1067371 non-null   float64 4
   Customer ID 824364 non-null   float64 5
   Country     1067371 non-null   object  6
   dtypes: float64(2), int64(1), object(4)
   memory usage: 65.1+ MB
```

Customer ID	Price	Quantity	
824364.000000	1.067371e+06	1.067371e+06	count
15324.638504	4.649388e+00	9.938898e+00	mean
1697.464450	1.235531e+02	1.727058e+02	std
12346.000000	5.359436e+04-	8.099500e+04-	min
13975.000000	1.250000e+00	1.000000e+00	25%
15255.000000	2.100000e+00	3.000000e+00	50%
16797.000000	4.150000e+00	1.000000e+01	75%
18287.000000	3.897000e+04	8.099500e+04	max


تعداد داده های ناموجود در هر ستون

na_proportion	na_count	
22.77	243007	Customer ID
0.41	4382	Description

na_proportion	na_count	
0.00	0	Invoice
0.00	0	StockCode
0.00	0	Quantity
0.00	0	Price
0.00	0	Country

حذف کشورها

همینطور که در نمودار زیر می بینیم اکثر داده های ما از کشور انگلیس میاد و کار درست این هست که فقط داده های فروش در این کشور مورد بررسی قرار بگیره



Customer Country	ID	Price	Quantity	Description	StockCode	Invoice	InvoiceDate
United Kingdom	13085.0	6.95	12	15CM CHRISTMAS GLASS BALL 20 LIGHTS	85048	489434	2009-12-01 07:45:00

Customer Country	ID	Price	Quantity	Description	StockCode	Invoice	InvoiceDate
United Kingdom	13085.0	6.75	12	PINK CHERRY LIGHTS	79323P	489434	2009-12-01 07:45:00
United Kingdom	13085.0	6.75	12	WHITE CHERRY LIGHTS	79323W	489434	2009-12-01 07:45:00
United Kingdom	13085.0	2.10	48	RECORD FRAME 7" SINGLE SIZE	22041	489434	2009-12-01 07:45:00
United Kingdom	13085.0	1.25	24	STRAWBERRY CERAMIC TRINKET BOX	21232	489434	2009-12-01 07:45:00

حذف بازگشت های عجیب و غریب

در اینجا با عدد های خیلی زیادی برخورد می کنیم که نشان دهنده درستی از بازگشت کالا توسط مشتری نیست! به همین دلیل میایم و بازگشت های بالاتر از ۵۰ تا را حذف میکنیم

```
,array([-3, -2, -6, -1, -12, -4, -24, -81,
       246-, 252-, 600-, 504-, 9-, 8-, 5-, 48-
      , 16-, 50-, 96-, 18-, 60-, 32-, 10-, 36-
      , 20-, 25-, 13-, 23-, 7-, 168-, 64-, 120-
      , 14-, 30-, 72-, 190-, 144-, 17-, 100-, 11-
      , 21-, 300-, 22-, 26-, 150-, 27-, 132-, 44-
      , 80-, 28-, 108-, 432-, 15-, 240-, 192-, 40-
      , 288-, 34-, 1440-, 38-, 408-, 200-, 42-, 74-
      , 140-, 280-, 500-, 400-, 19-, 309-, 160-, 204-
      , 49-, 51-, 312-, 69-, 1200-, 156-, 250-, 128-
      , 576-, 61-, 29-, 99-, 98-, 210-, 830-, 41-
      , 118-, 180-, 55-, 90-, 85-, 720-, 648-, 320-
      , 56-, 384-, 1152-, 700-, 59-, 31-, 35-, 324-
      , 213-, 212-, 256-, 248-, 2400-, 243-, 270-, 148-
      , 117-, 129-, 65-, 37-, 45-, 68-, 82-, 110-
      , 46-, 102-, 76-, 94-, 74215-, 47-, 9360-, 33-
      , 1350-, 960-, 3114-, 2000-, 1930-, 1300-, 670-, 58-
      , 121-, 75-, 360-, 164-, 480-, 420-, 1515-, 52-
      , 756-, 113-, 126-, 318-, 334-, 701-, 828-, 39-
      , 220-, 130-, 70-, 53-, 186-, 43-, 79-, 152-
      , 276-, 67-, 162-, 112-, 66-, 468-, 1296-, 840-
      ([ 80995-, 234-, 244-, 184-
```

حذف فروش هایی که کنسل شده اند که با حرف C اول ستون شماره خرید قرار گرفته شده.

دو ستون کمیت و قیمت دو ستون مهم برای ما هست تا با این دو ستون یک ستون جدید به نام قیمت کل بسازیم.

TotalPrice	Price	Quantity	InvoiceDate
83.4	6.95	12	07:45:00 2009-12-01


Total	Price	Quantity	InvoiceDate
81.0	6.75	12	07:45:00 2009-12-01
81.0	6.75	12	07:45:00 2009-12-01
100.8	2.10	48	07:45:00 2009-12-01
30.0	1.25	24	07:45:00 2009-12-01
...
23.4	1.95	12	12:31:00 2011-12-09
23.6	2.95	8	12:49:00 2011-12-09
30.0	1.25	24	12:49:00 2011-12-09
214.8	8.95	24	12:49:00 2011-12-09
70.8	7.08	10	12:49:00 2011-12-09

rows × 3 columns 930836

ستون قیمت کل که به عنوان متغیر مورد بررسی در این سری زمانی انتخاب می کنیم.

تغییر زمان داده ها

داده ها به صورت روزانه ، هفتگی و ماهانه در نمودار زیر قرار گرفته اند.



<Figure size 1000x1500 with 0 Axes>



TotalPrice	InvoiceDate	
47668.86	2009-12-01	0
55875.26	2009-12-02	1
72820.90	2009-12-03	2
37966.35	2009-12-04	3
9042.36	2009-12-05	4
...
85331.87	2011-12-05	734
52484.19	2011-12-06	735
55214.81	2011-12-07	736
78999.51	2011-12-08	737
196114.48	2011-12-09	738



rows × 2 columns 739

TotalPrice	InvoiceDate	
47668.86	2009-12-01	0
55875.26	2009-12-02	1
72820.90	2009-12-03	2
37966.35	2009-12-04	3
9042.36	2009-12-05	4
...
85331.87	2011-12-05	734
52484.19	2011-12-06	735
55214.81	2011-12-07	736
78999.51	2011-12-08	737
196114.48	2011-12-09	738


rows × 2 columns 604

بررسی داده های روزانه






Autocorrelation



Partial Autocorrelation



P_value : 0.8948919984918149

تست نشان میده که داده های مانع نیستند

TotalPrice


		InvoiceDate
	10.772055	2009-12-01
	10.930895	2009-12-02
	11.195772	2009-12-03
	10.544482	2009-12-04
	9.109786	2009-12-05

	11.354315	2011-12-05
	10.868286	2011-12-06
	10.919005	2011-12-07
	11.277210	2011-12-08
	12.186459	2011-12-09

rows × 1 columns 604

P_value : 0.4751320931105454

تست نشان میده که داده های مانا نیستند


**P_value : 4.577446411956347e-16**

داده ها مانا هستند


, 0.24187989353131847)
, 0.1
, 52
({{0.739 : '1%', 0.574 : '2.5%', 0.463 : '5%', 0.347 : '10%'}})

با نوجه به دو آزمون گذشته سری زمانی ما، مانا هستند


Autocorrelation




Partial Autocorrelation



ARIMA Forecast with 95% Confidence Interval



Autocorrelation




lb_pvalue	lb_stat	
0.715137	0.133200	1
0.808803	0.424399	2
0.854973	0.776945	3
0.667793	2.371447	4
0.722360	2.854798	5
0.000439	24.410788	6


lb_pvalue	lb_stat	
0.000346	26.906732	7
0.000014	36.523471	8
0.000032	36.544620	9
0.000003	44.397507	10

(0.8384036320090842 , 0.20393584678184795)

ARIMA Forecast with 95% Confidence Interval



Autocorrelation




lb_pvalue	lb_stat	
0.943498	0.005023	1
0.995566	0.008889	2
0.961898	0.289999	3
0.948748	0.720733	4
0.855589	1.953146	5
0.000119	27.462873	6
0.000168	28.646676	7
0.000011	37.134517	8
0.000023	37.334678	9
0.000007	42.063374	10

(0.7748311230208311 , 0.28606136345886335)

به دلیل اینکه در لگ ششم یک خودهمبستگی معنادار داریم از $p=6$ استفاده می کنیم


ARIMA Forecast with 95% Confidence Interval



lb_stat	lb_pvalue	
0.864403	0.029163	1
0.635926	0.905345	2
0.819544	0.924365	3
0.876270	1.211084	4
0.940610	1.243768	5
0.955102	1.564414	6
0.973752	1.718893	7
0.295876	9.578335	8
0.364381	9.830502	9
0.235203	12.797714	10
0.302727	12.857713	11
0.375724	12.908529	12


0.427698	13.263136	13
0.503921	13.288788	14
0.573466	13.373594	15
0.636423	13.493061	16
0.623725	14.607560	17
0.063305	27.918582	18
0.081529	28.099690	19
0.099839	28.419309	20
0.128567	28.422645	21
0.132448	29.450297	22
0.164229	29.502284	23
0.194049	29.724565	24
0.214523	30.264915	25
0.252502	30.371630	26
0.262528	31.211892	27
0.299937	31.392347	28
0.346835	31.399575	29
0.291459	33.737240	30
0.334373	33.785516	31
0.379670	33.819622	32
0.389729	34.636300	33
0.368935	36.138891	34
0.413039	36.185849	35
0.432790	36.775502	36
0.479434	36.776264	37
0.504952	37.228452	38
0.542814	37.402928	39
0.587126	37.417518	40
0.525380	39.766987	41
0.383003	44.096800	42
0.277143	48.004735	43
0.303197	48.303956	44
0.337281	48.402349	45
0.350903	49.074703	46
0.292038	51.800104	47
0.289743	52.926723	48
0.277470	54.367278	49
0.310532	54.403901	50

Autocorrelation



که همچنان در بعضی لگ ها هنوز معناداری داریم و از مدل قوی تری استفاده می کنیم


ARIMA Forecast with 95% Confidence Interval



lb_stat	lb_pvalue	
0.899809	0.015851	1
0.819366	0.398449	2
0.819635	0.923988	3
0.920446	0.928436	4
0.966887	0.944886	5
0.979951	1.135496	6
0.990587	1.214580	7
0.869256	3.863130	8

0.918320	3.892891	9
0.937300	4.211534	10
0.957500	4.378777	11
0.975542	4.380879	12
0.986372	4.384472	13
0.988584	4.785117	14
0.982648	5.817813	15
0.973624	6.981091	16
0.980606	7.213936	17
0.983661	7.629190	18
0.989970	7.636425	19
0.983367	8.959918	20
0.986893	9.273553	21
0.991401	9.334605	22
0.992283	9.829333	23
0.994543	10.000890	24
0.996645	10.002946	25
0.994942	11.176412	26
0.994996	11.808710	27
0.996661	11.884750	28
0.997382	12.190054	29
0.998258	12.279627	30
0.998924	12.286393	31
0.999240	12.471177	32
0.999404	12.784395	33
0.999620	12.853329	34
0.999774	12.854691	35
0.999779	13.421926	36
0.999855	13.539379	37
0.999899	13.725097	38
0.999931	13.884626	39
0.999932	14.452639	40
0.999734	16.683232	41
0.999715	17.399032	42
0.999187	19.573998	43
0.999365	19.847779	44
0.999551	19.973858	45
0.999683	20.100752	46
0.999184	22.260189	47
0.999162	22.984765	48
0.997368	25.850699	49
0.997980	26.025364	50

Autocorrelation





همانطور که در نمودار خودهمبستگی قابل مشاهده هست نمودار خودهمبستگی که داریم در فضای معنادار قرار داره و مدل ما کارش رو انجام دارد و ضرایب باکس-پیرز ما هم بالاتر از 0.15 هستند که لگ ها ما در موقعیتی خوبی قرار دارند

بررسی نهایی مدل


بررسی باقی مانده های مدل

Residual Analysis: ARIMA(6,0,6)(1,0,1)[12]



Comprehensive Residual Diagnostics**توان دوم باقی مانده ها**

- در بررسی توان دوم باقی مانده ها مشاهده شد که واریانس ما ثابت هست که از طریق رسم نمودار و بررسی خودهمبستگی آن اطمینان حاصل شد

Squared Residuals Analysis (Heteroscedasticity Check)**SQUARED RESIDUALS INTERPRETATION**

Mean of squared residuals: 0.175996
 Std of squared residuals: 0.337097
 Variance ratio (1st/2nd half): 1.06
 Time correlation: -0.0295

:WHAT TO LOOK FOR

GOOD: Random scatter around mean, no patterns ✓
 GOOD: Constant variance over time (ratio < 2) ✓
 GOOD: No autocorrelation in squared residuals (ARCH test p > 0.05) ✓
 GOOD: Moving average is roughly flat ✓



BAD: Increasing/decreasing trend over time ✗
 BAD: Periods of high variance followed by low variance ✗
 BAD: Autocorrelation in squared residuals (volatility clustering) ✗
 BAD: Fan-shaped pattern (variance increases with level) ✗

=====
OVERALL: Residuals show HOMOSCEDASTICITY (constant variance) ✓
 !Your model's variance assumptions are satisfied
 =====

نرمالیتی باقی مانده ها



- در این تست ها فقط در کلموگروف-اسمیرنوف مورد قبول شد و در تست ها دیگر مورد قبول در نظر گرفته نشد

Comprehensive Normality Analysis of Model Residuals



Test	Normality Test Results		Result
	Statistic	P-value	
Kolmogorov-Smirnov	0.0455	0.1644	Pass
Shapiro-Wilk	0.9786	0.0000	Fail
Jarque-Bera	80.8763	0.0000	Fail
Anderson-Darling	2.5388	0.7820*	Fail

* Anderson-Darling: Critical value at 5% significance
Note: P-value > 0.05 indicates normality



□ SIGNIFICANT NON-NORMALITY

Tests Passed: 1/4

Recommendation:
Residuals deviate significantly from normal.
Consider:

- Checking for outliers
- Log transformation
- Robust methods

===== NORMALITY TEST SUMMARY =====


Kolmogorov-Smirnov: stat=0.0455, p=0.1644
 Shapiro-Wilk: stat=0.9786, p=0.0000
 Jarque-Bera: stat=80.8763, p=0.0000
 Anderson-Darling: stat=2.5388

Skewness: -0.3521
 Kurtosis: 1.6616

داده های پرت در باقیمانده ها

- به نظر من وجود داده های پرت در باقی مانده به خاطر پیچیدگی داده ای که داشتم قابل حدس بود و رفتاری قابل پیش بینی

Comprehensive Outlier Detection Analysis



OUTLIER DETECTION SUMMARY

Total observations: 596

Method	Outliers_Detected	Percentage
IQR	22	3.69%
Z-Score	6	1.01%
Modified Z-Score	7	1.17%
Isolation Forest	30	5.03%

CONSENSUS OUTLIERS (detected by 2+ methods): 22

Index 2009-12-05 00:00:00: Value = -1.6824, Detected by 4 methods

Index 2009-12-21 00:00:00: Value = -1.5332, Detected by 4 methods
Index 2009-12-23 00:00:00: Value = -1.7251, Detected by 4 methods
Index 2011-09-20 00:00:00: Value = 1.3927, Detected by 4 methods
Index 2011-05-01 00:00:00: Value = -1.4071, Detected by 4 methods
Index 2010-12-22 00:00:00: Value = -1.6716, Detected by 4 methods
Index 2010-12-19 00:00:00: Value = -1.2552, Detected by 3 methods
Index 2011-01-11 00:00:00: Value = 0.9815, Detected by 2 methods
Index 2011-09-15 00:00:00: Value = 0.9966, Detected by 2 methods
Index 2011-05-29 00:00:00: Value = -1.0642, Detected by 2 methods
Index 2011-03-13 00:00:00: Value = -1.1778, Detected by 2 methods
Index 2011-02-06 00:00:00: Value = -1.1398, Detected by 2 methods
Index 2011-01-18 00:00:00: Value = 1.1122, Detected by 2 methods
Index 2010-12-23 00:00:00: Value = -0.9927, Detected by 2 methods
Index 2011-01-05 00:00:00: Value = 1.0864, Detected by 2 methods
Index 2009-12-20 00:00:00: Value = -1.0579, Detected by 2 methods
Index 2010-09-27 00:00:00: Value = 1.1836, Detected by 2 methods
Index 2010-07-15 00:00:00: Value = 1.0241, Detected by 2 methods
Index 2010-06-20 00:00:00: Value = -1.0380, Detected by 2 methods
Index 2010-06-07 00:00:00: Value = 1.0514, Detected by 2 methods
Index 2010-01-15 00:00:00: Value = -0.9758, Detected by 2 methods
Index 2011-10-03 00:00:00: Value = 0.9545, Detected by 2 methods

===== : IQR BOUNDS

Lower: -0.9600

Upper: 0.9482